

Estimasi Kepadatan Penumpang Kereta dengan Pemodelan *Crowd Counting*

Bryan Tjandra, Oey Joshua Jodrian, Nyoo Steven Christopher H., Alfian F. Wicaksono

{bryan.tjandra, oey.joshua, nyoo.steven, alfian} @ ui.ac.id

Fakultas Ilmu Komputer, Universitas Indonesia, Depok, 16424

Corresponding Author: Bryan Tjandra

INTISARI — Penelitian ini mengembangkan sebuah model berbasis *Artificial Intelligence* yang dapat memprediksi kepadatan penumpang kereta. Dengan menggunakan metrik yang kami usulkan (k -F1) dan dataset kepadatan KRL yang dibangun, kami membandingkan tiga buah pendekatan deteksi objek di keramaian, antara lain dengan prediksi *bounding box* (YOLOv5), *density map* (CSRNet), dan *proposal point* (P2PNet). Hasil penelitian menunjukkan bahwa P2PNet unggul dalam mengestimasi jumlah orang dan lokasi prediksi pada situasi padat. Namun, pada KRL dengan jumlah orang sedikit dan ukuran objek besar, YOLOv5 memiliki performa terbaik dengan tingkat *error* terendah dan waktu *inference* tercepat. Untuk mengestimasi kepadatan suatu ruang, diusulkan metode yang mempertimbangkan *region of interest* lokasi, mentransformasi perspektif gambar, dan melakukan *masking* berdasarkan kepala yang terdeteksi. Proporsi antara area *masking* dengan total area memberikan estimasi tingkat kepadatan secara eksak dalam KRL. Metode ini berpotensi untuk diaplikasikan pada sistem CCTV KRL berbasis citra secara *real time* dan untuk membantu penumpang dalam mengantisipasi kepadatan KRL serta memungkinkan PT. KCI untuk memonitor tingkat kepadatan secara otomatis.

KATA KUNCI — KRL, *Density Estimation*, *Crowd Counting*, YOLOv5, P2PNet, CSRNet, *Individual Localization*, *k*-Nearest FI

I. PENDAHULUAN

Transportasi kereta api KRL merupakan salah satu moda transportasi yang telah menjadi pilihan utama bagi banyak orang karena kenyamanan dan efisiensinya, terutama dalam mengatasi kemacetan di jalan raya yang semakin parah. Menurut data dari Badan Pusat Statistik, selama bulan Februari 2023, terdapat total 20,8 juta penumpang KRL dengan rata-rata 743 ribu penumpang setiap harinya¹. KAI memprediksi dalam 5 tahun mendatang, banyaknya penumpang KRL dapat mencapai 1,1 juta per hari². Meskipun banyaknya pengguna kereta api meningkat, tingkat kesesuaian antara harapan pengguna dengan kenyataan secara keseluruhan pada tahun 2019 hanya mencapai 65,47% [18]. Berdasarkan kajian kami (yang dapat dilihat pada Bagian IV), dari 2019 hingga Juni 2023, tingkat ketidakpuasan pengguna melalui sentimen cuitan di media sosial masih tinggi, mencapai angka 26,7%.

Kajian analisis kepuasan pengguna yang kami lakukan menyarankan bahwa ada beberapa isu masalah yang ditemukan dalam KRL. Salah satu isu utamanya adalah kapasitas KRL yang sering penuh. Meskipun rasio penumpang dan kapasitas angkut KRL masih luas, mencapai 63% per tahun 2023, KRL tetap sering penuh terutama pada jam sibuk². Alat pendeteksi kepadatan penumpang secara *real-time* dapat menjadi alternatif untuk menghindari kepadatan tersebut. Kami juga telah mewawancarai 10 petugas KRL dari berbagai jalur. Namun, mereka menyatakan bahwa belum ada alat untuk memprediksi kepadatan kereta. Hal ini membuat sulit bagi penumpang untuk mempersiapkan diri dan menghindari kereta yang terlalu penuh. Permasalahan ini dapat menyebabkan kesulitan bagi pengelola dalam mengatur jadwal kereta dan ketidakseimbangan antara banyaknya kereta yang tersedia dan permintaan penumpang.

Untuk mengatasi masalah tersebut, kami mengusulkan pengembangan kerangka model estimasi kepadatan penumpang

KRL. Pertama, kami melakukan analisis sentimen dan pemodelan topik terhadap sekumpulan pesan blog mikro Twitter untuk memastikan bahwa isu kepadatan memang penting untuk segera ditangani. Kedua, kami mengembangkan model *crowd counting* dan deteksi lokasi individu. Dalam pengembangannya, kami juga membangun dataset berupa sekumpulan gambar yang langsung diambil dari KRL dan berguna untuk evaluasi model; serta mengusulkan metrik baru untuk mengevaluasi kemampuan model dalam menentukan lokalisasi titik individu. Terakhir, kami mengusulkan sebuah metode untuk menghitung kuantitas kepadatan penumpang berdasarkan hasil pemodelan *crowd counting*.

Kontribusi akademis yang dihasilkan pekerjaan ini antara lain pengembangan model estimasi kepadatan pada KRL, dataset baru untuk evaluasi model *crowd counting* pada KRL, dan metrik baru untuk menilai kualitas model dalam memprediksi lokalisasi titik individu. Penelitian ini juga memiliki beberapa manfaat praktis, seperti (1) membantu PT KCI melihat dampak dari perubahan sistem KRL melalui tren kepadatan penggunaan KRL seiring waktu dan (2) meningkatkan infrastruktur transportasi yang efisien dan berkelanjutan (sesuai dengan SDGs nomor 11³), serta mendukung pertumbuhan industri KRL.

II. STUDI LITERATUR

Density estimation adalah cabang dari *computer vision* yang digunakan untuk mengestimasi kepadatan dalam sebuah gambar. Metode ini dapat menggunakan *crowd counting* [7, 5] yang hasilnya akan di-*mask* untuk menghasilkan segmentasi objek dan bermanfaat untuk memprediksi kepadatan [28]. Ada tiga pendekatan yang digunakan dalam metode *crowd counting* di penelitian ini, yaitu *bounding box*, *density map*, dan *proposal point*. *Bounding box* menghasilkan kotak pembatas di sekitar objek yang terdeteksi [16]. *Proposal point* menghasilkan prediksi titik lokasi pada tengah objek [3]. *Density map*

¹ Sumber: Badan Pusat Statistik ² Sumber: KAI

³ <https://sdgs.un.org/goals/goal11>

mengestimasi jumlah kerumunan dengan menetapkan nilai kepadatan untuk setiap sel *grid* dalam gambar [12]. Dalam kasus kepadatan di KRL, terdapat karakteristik objek seperti jumlah orang yang terbatas hingga 50 dalam satu gambar dan perbedaan ukuran antar objek karena perspektif kamera.

Salah satu model *state-of-the-art* yang terkenal dengan kecepatan dan akurasi dalam komputasi *bounding box* adalah YOLOv5. YOLOv5 terdiri atas lapisan *backbone* untuk mempercepat waktu inferensi [9], *neck* untuk meningkatkan arus informasi, dan *head* yang menghasilkan 3 peta fitur yang memungkinkan model menangani objek kecil, sedang, dan besar [25]. Namun, metode *bounding box* dapat melibatkan komputasi yang mahal untuk pelabelan dan sulit untuk menemukan lokasi objek yang tepat pada gambar yang jauh, ambigu, dan kompleks [24].

Salah satu model untuk komputasi *density map* adalah CSRNet [12]. CSRNet menggunakan *dilated convolutional neural network* untuk mengekstraksi informasi penting yang lebih dalam dan mempertahankan resolusi *output*. Lapisan konvolusi dilatasi menggunakan *sparse kernel* sebagai pengganti lapisan *pooling* untuk mencegah penurunan resolusi dan hilangnya informasi [12]. Meskipun *density map* cocok untuk mengestimasi objek yang padat, keakuratannya dalam menentukan lokasi eksak terbatas [22].

Density Estimation juga dapat dilakukan dengan memprediksi *proposal point*, seperti pada model P2PNet. Metode ini menggabungkan regresi untuk mendeteksi lokasi dan klasifikasi untuk menentukan *confidence score* dari *keypoints* [22]. Jika titik prediksi dekat dengan titik *ground truth* (GT), model akan memperbarui *confidence* menjadi lebih tinggi dan lokasinya menjadi lebih dekat dengan GT. Meskipun *proposal point* dapat memprediksi lokasi secara eksak, tetapi ia rentan terhadap *False Negative* pada perbedaan ukuran objek yang signifikan [22].

III. METODOLOGI

Penelitian ini terdiri dari tiga bagian utama. Pertama, kami mengembangkan model untuk mempelajari topik yang sering dibicarakan oleh masyarakat tentang KRL. Kedua, kami membandingkan performa dari tiga pendekatan untuk *crowd counting* dan mengestimasi lokasi individu. Ketiga, model untuk menghitung kepadatan penumpang dikembangkan berdasarkan metode terbaik yang diperoleh sebelumnya. Kami juga akan merincikan dataset yang digunakan dan metode evaluasi k-F1 yang kami usulkan.

Dataset. Seperti yang terlihat pada Tabel 1, *dataset* yang digunakan terdiri dari dua *dataset* citra dan satu *dataset* teks. Kami melakukan *scraping* dari Twitter dengan jumlah 20K cuitan yang berhubungan dengan KRL dari tahun 2019–2023. Gambar untuk data latih *crowd counting* masyarakat umum diperoleh dari institusi pendidikan ShanghaiTech [13] dan stasiun di China [26]. Lalu, kami juga melakukan pengambilan 150 data secara langsung berupa gambar kepadatan penumpang KRL pada kondisi kereta yang bervariasi.

Satisfaction Analysis. Sebagai langkah awal, kami melakukan analisis topik terhadap pesan berorientasi sentimen negatif

Dataset	Tujuan	Ukuran
Kepadatan masyarakat	Pelatihan Model	3,323
Kepadatan penumpang KRL	Evaluasi Model	150
Pesan Twitter	Analisis kepuasan	20,000

Tabel 1: Dataset yang digunakan dalam penelitian

pada *dataset* Twitter berukuran 20K yang sudah dijelaskan sebelumnya. Pemberian label secara manual ke semua cuitan tentunya sangat memakan waktu. Oleh karena itu, kami menerapkan pendekatan *Semi-Supervised Learning* dengan *Pseudo-labelling* [11]. Pertama, kami memberi label orientasi sentimen (positif, negatif, dan tidak relevan) secara manual sebanyak 400 cuitan. Kemudian, model berbasis BERT [10, 17] dilatih dengan 400 cuitan berlabel tersebut dan digunakan untuk memprediksi label ke 19,600 sisa cuitan.


Cuitan dengan tingkat *confidence* hasil prediksi lebih dari 0,9 digabung dengan data anotasi awal untuk kebutuhan pelatihan ulang. Setelah model kembali dilatih dan digunakan untuk memberi label ulang ke 19,600 cuitan, kami lalu memilih cuitan dengan label orientasi negatif (baik itu hasil label manual maupun hasil *pseudo-labelling*) untuk kemudian dilakukan pemodelan topik guna mengidentifikasi isu negatif terkait penggunaan KRL. Sebagai informasi, kami menggunakan BERTopic [8, 21] untuk ekstraksi topik dan juga memproses teks cuitan tentang KRL menggunakan API dari GPT-3.5 [2, 27] dan *library* *tweet-preprocessor*⁴.

Crowd Counting & Individual Localization. Seperti yang akan disampaikan pada Bagian IV, hasil analisis pada dataset Twitter menyarankan adanya sistem yang dapat memprediksi kepadatan penumpang KRL. Oleh karena itu, tahap berikutnya adalah pengembangan model prediksi kepadatan menggunakan *crowd counting* di KRL. Dalam hal ini, kami menggunakan deteksi berbasis kepala karena tubuh penumpang dapat tertutup oleh objek lain [6].

Kami membandingkan beberapa metode yang dapat digunakan untuk menghitung jumlah keramaian dan melokalisasi objek deteksi. Yang perlu dicatat adalah bahwa menghitung jumlah orang yang terdeteksi saja tidaklah cukup, tetapi juga harus mampu melokalisasi objek dengan akurat. Kemudian, data citra yang digunakan akan diproses terlebih dahulu dengan melibatkan tahap *cropping*, *resizing*, dan *augmentasi* gambar. Selanjutnya, gambar-gambar tersebut akan di-*fine-tune* menggunakan tiga pendekatan deteksi objek keramaian: (1) *Proposal Points*, (2) *Density Map*, dan (3) *Bounding Box*, seperti yang diilustrasikan dalam Gambar 1.

Untuk menentukan pendekatan deteksi objek terbaik, kami mengevaluasi performa mereka menggunakan metrik *Mean Absolute Percentage Error* (MAPE) untuk mengestimasi kesalahan jumlah orang yang diprediksi, serta metrik *k-Nearest F1 Score* (k-F1) yang kami usulkan untuk mengukur performa estimasi lokalisasi titik. Penggunaan MAPE lebih dijadikan acuan dibandingkan MAE karena jumlah orang dalam satu


⁴ <https://pypi.org/project/tweet-preprocessor/>



Gambar 1: Perbandingan metode untuk *crowd counting* dengan *bounding box*, *density map*, dan *proposal point*

gambar dapat bervariasi. Untuk menentukan lokasi yang tepat pada *bounding box*, kami akan menggunakan titik tengah sehingga ketika estimasi kepadatan dilakukan, *masking* yang dihasilkan akan memiliki bentuk lingkaran yang menyesuaikan dengan bentuk kepala, bukan kotak. Sedangkan untuk *density map*, kami akan menerapkan *thresholding* untuk menentukan lokasi hasil prediksi secara diskrit.

k-Nearest F1 Score. Untuk mengevaluasi estimasi lokalisasi titik individu, salah satu metrik yang dapat digunakan adalah *Normalized Average Precision* (nAP) [22]. Namun, metrik nAP masih memberikan penekanan pada konsekuensi dari deteksi objek yang salah, yaitu ketika terdapat banyak *False Positive* (FP). Oleh karena itu, kami mengusulkan metrik baru yang efektif untuk mengevaluasi estimasi lokalisasi poin dengan tujuan mengurangi jumlah deteksi (FP dan FN) secara seimbang, yang disebut *k-Nearest F1 Score* (k-F1). Metrik ini tidak hanya mempertimbangkan perbedaan jarak antara titik prediksi dan *ground truth* (GT), tetapi juga menggunakan *confidence score* dari hasil prediksi.



Gambar 2: Proses perhitungan k-F1 (kiri) dan ilustrasi perhitungan *region* berdasarkan 3-*nearest* GT (kanan)

Gambar 2 sebelah kiri mengilustrasikan cara kerja metrik k-F1. Pertama, titik-titik anggota himpunan titik prediksi $\mathcal{X}$ diurutkan berdasarkan *confidence score*. Kedua, secara berurutan, setiap titik prediksi $x \in \mathcal{X}$ dicari *k-nearest* GT beserta rata-rata jarak *euclidean* terhadap titik prediksi x , yang dinyatakan sebagai $d_k(x)$. Hal ini diilustrasikan pada Gambar 2 sebelah kanan. Terakhir, $d_k(x)$ digunakan sebagai batas untuk


menentukan apakah $x \in \mathcal{X}$ merupakan *True Positive* (TP) atau *False Positive* (FP), atau secara formal:

$$I(x) = \begin{cases} 1 & \text{jika } d_k(x) < \lambda \cdot d_p(x) \\ 0 & \text{sebaliknya,} \end{cases}$$

dengan $I(x)$ adalah sebuah fungsi indikator yang bernilai 1 jika titik prediksi x dianggap TP dan 0 jika dianggap FP; $d_p(x)$ adalah jarak *euclidean* antara titik prediksi x dengan GT terdekat; dan λ adalah faktor restriksi.

GT yang telah dianggap mirip dengan prediksi tidak akan dipertimbangkan lagi untuk perhitungan *k-nearest* berikutnya. Setelah selesai mengevaluasi prediksi dengan *confidence* tertinggi, proses akan dilanjutkan dengan prediksi berikutnya yang memiliki *confidence* terbesar, dan seterusnya. Setelah semua prediksi dievaluasi, GT yang tidak terhubung akan dianggap sebagai *False Negative* (FN). Dari nilai TP, FP, dan FN tersebut, nilai F1 dapat dihitung, yang kemudian diberi nama k-F1.

Density Estimation. Dalam melakukan estimasi kepadatan, kami melibatkan pengambilan area tertentu dari gambar KRL untuk mengestimasi kepadatan dengan asumsi kepadatan bersifat *uniform*, sehingga dapat digeneralisasi untuk seluruh gerbong. Estimasi kepadatan dilakukan dengan hanya memperhatikan area yang dicakup oleh kepala, mengingat penggunaan seluruh tubuh dapat menghasilkan *bias* karena ruang yang dicakup tubuh dari pandang kamera, sebenarnya masih dapat diisi objek lain. Kami akan menggunakan *few-shot transfer learning* [20] dengan menggunakan ketiga model *crowd counting* sebelumnya dan data kepadatan KRL Indonesia yang dikumpulkan oleh tim peneliti. Sebanyak 150 gambar akan melalui proses *human-in-the-loop labelling* [15], di mana 1/3 data akan digunakan untuk *transfer learning* dan sisanya untuk *validation*.



Gambar 3: Proses untuk mengestimasi kepadatan

Gambar 3 mengilustrasikan secara umum langkah-langkah dalam melakukan estimasi kepadatan. Pertama, kita akan menentukan *region of interest* yang akan ditransformasi sudut

pandangannya menggunakan *Homography matrix* sehingga perspektif kamera terlihat seolah-olah diambil dari atas [23]. Transformasi ini dilakukan untuk memastikan ukuran kepala menjadi seragam [1]. Setelah dilakukan transformasi, ukuran prediksi *titik* akan disesuaikan dengan ukuran kepala.

Kemudian, untuk mendapatkan konstanta yang digunakan sebagai faktor pembesaran titik supaya mencakup area kepala, kami mengambil rata-rata radius titik yang dapat menutupi kepala dari 50 observasi gambar. Karena ukuran kepala laki-laki dan perempuan secara umum memiliki standar deviasi yang kecil, dapat diasumsikan bahwa ukuran kepala orang-orang relatif serupa [19]. Oleh karena itu, pengalihan dengan konstanta saja masih relevan. Selanjutnya, akan dilakukan *clustering* menggunakan algoritma DBSCAN [4] untuk menghasilkan area yang tidak memiliki ruang dari jarak kepala yang berdekatan, karena ruang tersebut sebenarnya tidak dapat diisi objek lagi. Untuk memastikan bahwa titik dapat menyesuaikan ukuran kepala, akan ditambahkan 12 titik pada radius r cm dan 9 titik dengan pada radius $r/2$ cm, seperti yang ditunjukkan pada Gambar 3 (c). Setelah mendapatkan *cluster* yang ada, kami menggunakan algoritma *concave hull* [14] untuk membentuk area segmentasi dari setiap *cluster* tersebut. Selanjutnya, estimasi kepadatan akan dihitung dengan membagi jumlah piksel pada area segmentasi dengan jumlah piksel pada *region of interest*.

IV. HASIL EKSPERIMEN DAN ANALISIS

Satisfaction Analysis. Pada tahap awal, kami membangun model IndoBERT untuk memprediksi relevansi isu KRL dengan skor validasi F1 sebesar 0,86. Hasil prediksi kemudian disaring hanya untuk konteks yang relevan dengan isu KRL, sehingga diperoleh 10,128 cuitan yang relevan. Selanjutnya, kami menggunakan dua model berbasis BERT untuk sentimen, yaitu milik *ayameRushia* dan *w1lwo*. Hasilnya menunjukkan bahwa model *ayameRushia* mencapai Skor F1 sebesar 0,803, sementara model *w1lwo* mencapai sebesar 0,95. Setelah di *fine-tuned*, skor F1 model *w1lwo* meningkat menjadi 0,965.

Dari 10,128 cuitan yang dianalisis menggunakan model *fine-tuned w1lwo*, sebanyak 26,7% cuitan memiliki sentimen negatif. Kami melakukan analisis lebih lanjut untuk mengidentifikasi topik-topik yang menjadi penyebab sentimen negatif tersebut. Dengan menggunakan model BERTopic, kami berhasil mengidentifikasi topik-topik yang relevan, seperti yang terlihat pada Tabel 2.

Topik	Keyword	Persentase
Kepadatan kapasitas KRL	<i>krl_padet</i>	19,2%
Keterlambatan Kedatangan	<i>krl_datang_lambat</i>	13,9%
Kasus Pelecehan Seksual	<i>seksual_pelecehan</i>	9,1%

Tabel 2: Tiga topik isu KRL terbanyak

Berdasarkan hasil yang diperoleh, topik yang paling sering muncul dalam cuitan adalah kepadatan kapasitas KRL. Ini yang menjadi basis kami dalam mengembangkan model estimasi kepadatan penumpang KRL.

Crowd Counting & Localization. Untuk melakukan estimasi kepadatan, kami menggunakan metode *crowd counting* dan *individual localization* dengan membandingkan tiga metode yang berbeda untuk dua jenis *dataset* ShanghaiTech: (1) *dataset A* yang memiliki maksimal 2000 orang per frame, dan (2) *dataset B* yang memiliki maksimal 500 orang per frame.

Metode	Dataset	MAPE	nAP	k-F1	Time
Yolov5	A	0,58	0,65	0,64	0,307
	B	0,21	0,87	0,85	0,204
CSRNet	A	0,30	0,36	0,34	0,332
	B	0,17	0,40	0,37	0,221
P2PNet	A	0,15	0,92	0,90	0,408
	B	0,16	0,94	0,91	0,276

Tabel 3: Perbandingan hasil untuk *dataset A* dan *B*


Tabel 3 menunjukkan hasil evaluasi untuk *dataset A* dan *dataset B*. Dari hasil tersebut, dapat dilihat bahwa metode P2PNet memiliki nAP, MAPE, dan k-F1 ($k = 3$, $\lambda = 0.75$) terbaik. Model CSRNet memiliki nilai MAPE yang sedikit lebih buruk daripada P2PNet karena hasil prediksi yang berupa estimasi regresi dari banyaknya objek yang terdeteksi; namun lebih baik dari YOLOv5 karena metode regresi pada CSRNet sesuai jika digunakan pada objek yang padat. Kemudian, CSRNet memiliki performa nAP dan k-F1 yang lebih rendah dibandingkan P2PNet dan YOLOv5. Kami menduga bahwa kemampuan lokalisasi CSRNet berkurang akibat adanya *noise* yang tinggi ketika dilakukan *thresholding*. Model YOLOv5 memiliki performa MAPE yang paling buruk. Meskipun demikian, YOLOv5 memiliki *inference time* yang paling cepat dibandingkan dengan model lainnya.

Perbandingan deteksi lokasi objek diskrit antara YOLOv5 dan P2PNet dapat dilihat pada Gambar 4 (c), di mana terlihat bahwa YOLOv5 masih memiliki banyak FN, yaitu dari kepala yang tidak terdeteksi. Tabel 3 menunjukkan perbedaan hasil antara k-F1 dan nAP. Metrik nAP lebih fokus pada penalti pada FP, sedangkan k-F1 memberikan penekanan pada penalti pada FP dan FN. Penalti yang lebih berat ini dikarenakan kesalahan deteksi dapat menyebabkan estimasi kepadatan yang tidak akurat.

Metode	MAE	MAPE	k-F1
Yolov5	1.41	0.129	0.91
CSRNet	4.98	0.927	0.35
P2PNet	3.49	0.309	0.77

Tabel 4: Perbandingan hasil untuk Dataset KRL

Selanjutnya, kami juga melakukan evaluasi ketiga model pada dataset kepadatan KRL. Kami menggunakan metode *few-shot transfer learning* dengan melibatkan 50 gambar KRL, diikuti dengan proses *validation* menggunakan 100 gambar lainnya. Hasil prediksi dan evaluasi metrik dapat dilihat pada Gambar 4 (a) dan Tabel 4. Dari hasil evaluasi tersebut, terlihat bahwa YOLOv5 memiliki performa terbaik dalam



Gambar 4: Hasil (a) *crowd counting* dan (b) estimasi kepadatan, serta (c) contoh hasil perbandingan prediksi YOLOv5 dan P2PNet pada objek yang padat

metrik MAE, MAPE, dan k-F1. Keunggulan YOLOv5 terletak pada kemampuannya untuk mendeteksi dengan akurat pada objek yang memiliki ukuran yang cukup besar, seperti yang ditemukan dalam KRL dan jumlahnya tidak terlalu banyak. P2PNet, di sisi lain, memiliki performa yang lebih buruk dalam kasus objek dengan ukuran yang cenderung besar, tetapi mampu mendeteksi dengan baik pada objek yang padat dan berjumlah banyak, seperti yang terlihat pada ujung KRL dengan banyak orang. CSRNet juga lebih baik dalam mengestimasi objek yang padat, tetapi tidak dapat melokalisasi dengan akurat, sehingga menghasilkan skor k-F1 yang rendah.


Density Estimation. Setelah itu, ketiga model juga akan dievaluasi untuk menentukan model terbaik untuk estimasi kepadatan. Berdasarkan hasil yang tercantum dalam Tabel 4, terlihat bahwa model YOLOv5 memberikan performa terbaik. Untuk mendukung temuan ini, kami juga menunjukkan hasil estimasi kepadatan dalam Gambar 4 (b). Terlihat bahwa pada P2PNet masih terdapat area kepala yang tidak tercakup, pada CSRNet terdapat beberapa *noise* yang mengakibatkan estimasi kepadatan yang belum akurat, sedangkan pada YOLOv5, area telah tercakup dengan baik. Berdasarkan hasil ini, dapat disimpulkan bahwa metode *bounding box* (YOLOv5) merupakan metode terbaik untuk kasus estimasi kepadatan di dalam KRL dibandingkan dengan metode lainnya.

Selanjutnya, kami akan mengklasifikasikan persentase kepadatan menjadi tiga kategori, yaitu sepi, sedang, dan padat. Untuk melakukan ini, kami melakukan wawancara kepada 30 responden dengan menggunakan 50 gambar sebagai acuan. Hasil wawancara tersebut kemudian dihitung untuk mendapatkan 90% confidence interval, dan hasil tersebut disesuaikan, seperti tercantum dalam Tabel 5.

Setelah mendapatkan hasil wawancara, kami mengambil rata-rata dari batas interval untuk setiap kategori. Hasil yang telah disesuaikan juga terdapat pada Tabel 5. Contoh hasil estimasi kepadatan pada kondisi KRL sedang dan padat ditunjukkan dalam Gambar 5.

Hasil	Sepi	Sedang	Padat
Wawancara	21.2%-39.7%	45.3%-66.4%	71.2%-86.8%
Disesuaikan	0%-42.0%	42.0%-68.8%	68.8 %-100%

Tabel 5: Rentang kategori keramaian KRL



Gambar 5: Kategori dan persentase keramaian KRL

Dengan hasil yang kami peroleh, metode ini dapat diimplementasikan lebih lanjut pada kamera pengawasan CCTV untuk memonitor tingkat kepadatan di dalam KRL.

V. KESIMPULAN

Kami memulai pekerjaan ini dengan mengembangkan model untuk menganalisis orientasi sentimen dan topik terkait isu transportasi. Kami kemudian mengimplementasikan pendekatan estimasi kepadatan melalui berbagai metode *crowd counting*. Dalam konteks kepadatan KRL, yang ditandai dengan jumlah individu yang relatif sedikit namun berukuran besar, metode YOLOv5 mampu melakukan *crowd counting* dan *individual localization* dengan baik pada objek berukuran sedang hingga besar. Namun, YOLOv5 dapat menghasilkan *False Negative* pada objek berukuran kecil. Dengan menggunakan metode estimasi kepadatan berbasis YOLOv5 pada sistem CCTV, penumpang dapat lebih mudah mengantisipasi kepadatan di dalam KRL. Sebagai tambahan, kami juga mendemonstrasikan bahwa metrik k-F1 bermanfaat untuk evaluasi lokalisasi titik individu. Sebagai penutup, pekerjaan ini diharapkan bermanfaat untuk pengelolaan transportasi di masa mendatang.

REFERENSI

- [1] S. Basalamah, S. Khan, and H. Ullah. Scale driven convolutional neural network model for people counting and localization in crowd scenes. *IEEE Access*, PP:1–1, 05 2019. doi: 10.1109/ACCESS.2019.2918650.
- [2] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei. Language models are few-shot learners, 2020.
- [3] H. Chen and H. Zheng. Object detection based on center point proposals. *Electronics*, 9:2075, 12 2020.
- [4] D. Deng. Dbscan clustering algorithm based on density. In *2020 7th International Forum on Electrical Engineering and Automation (IFEEA)*, pages 949–953, 2020. doi: 10.1109/IFEEA51475.2020.00199.
- [5] Z. Fan, H. Zhang, Z. Zhang, G. Lu, Y. Zhang, and Y. Wang. A survey of crowd counting and density estimation based on convolutional neural network. *Neurocomputing*, 472:224–251, 2022. ISSN 0925-2312. doi: <https://doi.org/10.1016/j.neucom.2021.02.103>. URL <https://www.sciencedirect.com/science/article/pii/S0925231221016179>.
- [6] P. F. Felzenszwalb, R. B. Girshick, D. McAllester, and D. Ramanan. Object detection with discriminatively trained part-based models. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 32(9):1627–1645, 2010.
- [7] G. Gao, J. Gao, Q. Liu, Q. Wang, and Y. Wang. Cnn-based density estimation and crowd counting: A survey, 2020.
- [8] M. Grootendorst. Bertopic: Neural topic modeling with a class-based tf-idf procedure. *arXiv preprint arXiv:2203.05794*, 2022.
- [9] M. Horvat, L. Jelečević, and G. Gledec. A comparative study of yolov5 models performance for image localization and classification. 09 2022.
- [10] F. Koto, A. Rahimi, J. H. Lau, and T. Baldwin. Indolem and indobert: A benchmark dataset and pre-trained language model for indonesian nlp, 2020.
- [11] D.-H. Lee. Pseudo-label : The simple and efficient semi-supervised learning method for deep neural networks. *ICML 2013 Workshop : Challenges in Representation Learning (WREPL)*, 07 2013.
- [12] Y. Li, X. Zhang, and D. Chen. Csrnet: Dilated convolutional neural networks for understanding the highly congested scenes, 2018.
- [13] W. Liu, D. L. W. Luo, and S. Gao. Future frame prediction for anomaly detection – a new baseline. In *2018 IEEE CVPR*, 2018.
- [14] A. Moreira and M. Santos. Concave hull: A k-nearest neighbours approach for the computation of the region occupied by a set of points. pages 61–68, 01 2007.
- [15] E. Mosqueira-Rey, E. Hernández-Pereira, D. Alonso-Ríos, and et al. Human-in-the-loop machine learning: a state of the art. *Artificial Intelligence Review*, 56:3005–3054, 2023. doi: 10.1007/s10462-022-10246-w. URL <https://doi.org/10.1007/s10462-022-10246-w>.
- [16] N. Nufus, D. M. Ariffin, and A. S. Satyawan. Sistem pendeteksi pejalan kaki di lingkungan terbatas berbasis ssd mobilenet v2 dengan menggunakan gambar 360° ternormalisasi. *Prosiding SENASTINDO*, 3:123–134, December 2021.
- [17] K. S. Nugroho, A. Y. Sukmadewa, H. Wuswilahaken DW, F. A. Bachtiar, and N. Yudistira. Bert fine-tuning for sentiment analysis on indonesian mobile apps reviews. In *Proceedings of the 6th International Conference on Sustainable Information Engineering and Technology*, SIET '21, page 258–264, New York, NY, USA, 2021. Association for Computing Machinery. ISBN 9781450384070. doi: 10.1145/3479645.3479679. URL <https://doi.org/10.1145/3479645.3479679>.
- [18] D. I. Nurcahya. *Tingkat kepuasan pengguna terhadap pelayanan KRL commuter line rute Bogor-Jakarta Kota*. PhD thesis, Lontar UI, 2019.
- [19] A. Ormeci, H. Gürbüz, A. Ayata, and H. Cetin. Adult head circumferences and centiles. *Journal of Turgut Ozal Medical Center*, 3:261–264, 01 1997.
- [20] A. Parnami and M. Lee. Learning from few examples: A summary of approaches to few-shot learning, 2022.
- [21] S. Sawant, J. Yu, K. Pandya, C.-K. Ngan, and R. Bardeli. An enhanced bertopic framework and algorithm for improving topic coherence and diversity. pages 2251–2257, 2022. doi: 10.1109/HPCC-DSS-SmartCity-DependSys57074.2022.00332.
- [22] Q. Song, C. Wang, Z. Jiang, Y. Wang, Y. Tai, C. Wang, J. Li, F. Huang, and Y. Wu. Rethinking counting and localization in crowds: a purely point-based framework, 2021.
- [23] T. Sung and H. J. Lee. Images alignment using homography transformation matrix. 10 2018.
- [24] X.-T. Vo and K.-H. Jo. Accurate bounding box prediction for single-shot object detection. *IEEE Transactions on Industrial Informatics*, 18(9):5961–5971, 2022.
- [25] R. Xu, J. Li, and Y. Liu. An improved forest fire and smoke detection model based on yolov5. *Forests*, 14:833, April 2023. doi: 10.3390/f14040833.
- [26] J. Yang and M. Gong. Metrostation dataset, 2022. URL <https://doi.org/10.6084/m9.figshare.20521848.v1>.
- [27] J. Ye, X. Chen, N. Xu, C. Zu, Z. Shao, S. Liu, Y. Cui, Z. Zhou, C. Gong, Y. Shen, J. Zhou, S. Chen, T. Gui, Q. Zhang, and X. Huang. A comprehensive capability analysis of gpt-3 and gpt-3.5 series models. *ArXiv*, abs/2303.10420, 2023.
- [28] X. Zhang, Y. Sun, Q. Li, X. Li, and X. Shi. Crowd density estimation and mapping method based on surveillance video and gis. *ISPRS International Journal of Geo-Information*, 12(2):56, 2023. doi: 10.3390/ijgi12020056.